

Clasificación biclase de calidad de citricos en una SBC usando CNN

Ángel Dagoberto Cantú Castro*

Línea de Investigación del Posgrado: Sistemas Inteligentes & Universidad Politécnica de Victoria

Clasificación de calidad de citricos con una Raspberry Pi 5 por medio de redes neuronales

Director: Dr. Yahir Hernández Mier, Codirector: Dr. Marco Aurelio Nuño Maganda

Problemática

- La Raspberry Pi 5 cuenta con una capacidad limitada de recursos computacionales, lo cual afecta el tiempo de ejecución de un modelo.
- Conseguir una precisión mayor al 95 % para su implementación en más proyectos.

Trabajo Preliminar

- Se hará uso de un dataset de kaggle que cuenta con 2000 imágenes de limon (Citrus lemon) clasificados en 2 calidades.

Propuesta de Solución

Se propone el desarrollo de una arquitectura ligera y eficiente para la **clasificación binaria del Lemon citrus** (*bueno / malo*) capaz de poder ejecutarse en la **Raspberry Pi 5**. El objetivo principal es demostrar que un sistema compacto y de bajo costo puede alcanzar **altos niveles de precisión y velocidad** en entornos controlados, empleando redes neuronales convolucionales pequeñas.

La solución contempla la siguiente arquitectura de la red:




Figura: Diagrama de flujo de la arquitectura propuesta para la CNN binaria

- Procesamiento del dataset:** Una vez recibidas la imágenes se les hará una reducción de tamaño para que tenga una dimensión de 96x96 y se obtendrá la escala en grises para una mayor reducción de peso del modelo, aparte la división del dataset estará repartida 80 % train, 10 % validation y 10 % test.
- Parámetros del entrenamiento:** El entrenado sera en colab utilizando tensorflow, el optimizador Adam, callbacks como Earlystoppig y ModelCheckpoint. Ademas se realizo el entrenamiento haciendo uso de 3 learning rate: 0.001,0.0001 y 0.00001 repitiendo 10 veces cada uno de estos.
- .keras a tensorflow lite:** Para cumplir uno el objetivo de la velocidad en la ejecución se convirtió el modelo a .ftlite y con una cuantización mejorando su inferencia en dispositivo como la Raspbery


Resultados

Como resultado de los entrenamientos se selecciono el learning rate de 0.0001 que fue el que dio mejores resultados de forma mas consistente como se puede observa en la tabla 1 donde se muestran 2 resultados, el mas alto y el mas bajo de los 10 entrenamientos.

Precision	Recall	F1-score	accuracy
0.99	1.0	1.0	1.0
0.97	0.96	0.97	0.97


Cuadro: Métricas del modelo.

La gráfica del entrenamiento del mejor modelo y su matriz de confusion



Evolución de la accuracy (train/val).


Evolución de la loss (train/val).



Matriz de confusión del modelo cuantizado INT8 en prueba.

Los resultados del modelo ya convertido en tflite y cuantizado son una reduccion del 90 % del peso del archivo y una precision 98.6 % asi como lo muestra la tabla de metricas.

Métrica (macro avg)	Valor
Precisión (Precision)	0.9873
Exhaustividad (Recall)	0.9848
F1-Score	0.9859
Accuracy (global)	0.9860



Matriz de confusión del modelo cuantizado INT8 en prueba.

Rendimiento y velocidad

El conjunto completo de **2076** imágenes se procesó en la Raspberry obteniendo un buen tiempo de **14.62 s**, lo que implica:

$$\text{tiempo/imagen} = \frac{14.62}{2076} \text{ s} \approx 7.04 \text{ ms/imagen}$$

Logrando los objetivos de un modelo ligero y preciso

=====